

Master MIAHS

Modèles Linéaires Mixtes

Christian Lavergne et Catherine Trottier

Année universitaire 2016-2017

Le modèle linéaire gaussien à structure de covariance paramétrée et séparable ($\beta \perp \theta$)

- **Définition** $Y = X\beta + \epsilon$, avec X de dimension $n \times p$
 $\epsilon \sim \mathcal{N}_{\mathbb{R}^n}(0, \Gamma_\theta)$ avec θ paramètre inconnu de \mathbb{R}^K .

- **La vraisemblance**

$$f(\beta, \theta; y) = \frac{1}{(2\pi)^{n/2}} |\Gamma_\theta|^{-1/2} \exp\left\{-\frac{1}{2}(y - X\beta)' \Gamma_\theta^{-1} (y - X\beta)\right\}$$

$$\text{et } l(\beta, \theta) = -2 \log(f(\beta, \theta; y))$$

- **Cas particulier : le modèle linéaire élémentaire.** Repose sur l'hypothèse d'erreur gaussienne et de structure de covariance $\sigma_\epsilon^2 \Gamma$ avec Γ connue. Le cas le plus répandu étant $\Gamma = \text{Id}_n$.

Le maximum de vraisemblance dans un modèle linéaire général

- Estimateur du maximum de vraisemblance : ML

$$\hat{\beta}_{ML} = \arg \min_{\beta} ((y - X\beta)' \Gamma_{\theta}^{-1} (y - X\beta))$$

$$\hat{\theta}_{ML} = \arg \min_{\theta} ((y - X\beta)' \Gamma_{\theta}^{-1} (y - X\beta) + \log(|\Gamma_{\theta}|))$$

- Fonction score

$$\begin{aligned} U_{\beta}(\hat{\theta}_{ML}) &= \left. \frac{\partial l(\beta, \theta)}{\partial \beta} \right|_{\theta=\hat{\theta}_{ML}} \\ &= -2 X' \Gamma_{\theta}^{-1} (y - X\beta) \Big|_{\theta=\hat{\theta}_{ML}} \end{aligned} \quad (1)$$

donc $\hat{\beta}_{ML} = (X' \Gamma_{\hat{\theta}_{ML}}^{-1} X)^{-1} X' \Gamma_{\hat{\theta}_{ML}}^{-1} y$.

$$\begin{aligned}
U_{\theta}^{ML}(\hat{\beta}_{ML}) &= \left. \frac{\partial l(\beta, \theta)}{\partial \theta} \right|_{\beta=\hat{\beta}_{ML}} \\
&= \left. -(y - X\beta)' \Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta} \Gamma_{\theta}^{-1} (y - X\beta) + \text{tr}(\Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta}) \right|_{\beta=\hat{\beta}_{ML}} \\
&= -y' P_{\theta} \frac{\partial \Gamma_{\theta}}{\partial \theta} P_{\theta} y + \text{tr}(\Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta}) \quad (2)
\end{aligned}$$

où

- $P_{\theta} = \Gamma_{\theta}^{-1} (\text{Id} - X(X' \Gamma_{\theta}^{-1} X)^{-1} X' \Gamma_{\theta}^{-1})$,
- $u' A_{\theta} \frac{\partial \Gamma_{\theta}}{\partial \theta} A_{\theta} u$ est le vecteur de composantes $[u' A_{\theta} \frac{\partial \Gamma_{\theta}}{\partial \theta_j} A_{\theta} u]_{j=1, \dots, K}$
- resp. $\text{tr}(A_{\theta} \frac{\partial \Gamma_{\theta}}{\partial \theta}) = [\text{tr}(A_{\theta} \frac{\partial \Gamma_{\theta}}{\partial \theta_j})]_{j=1, \dots, K}$

rappel : $\frac{\partial \Gamma_{\theta}^{-1}}{\partial \theta_j} = -\Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta_j} \Gamma_{\theta}^{-1}$ et $\frac{\partial \log(|\Gamma_{\theta}|)}{\partial \theta_j} = \text{tr}(\Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta_j})$

Estimation du paramètre de dispersion σ^2 : cas $\Gamma_\theta = \sigma^2 \text{Id}$

$\hat{\sigma}^2 = \frac{1}{n-p} \|Y - X\hat{\beta}\|^2$ est un estimateur sans biais de σ^2 .

$$\begin{aligned}\|Y - X\hat{\beta}\|^2 &= \|Y - X(tXX)^{-1}tXY\|^2 \\ &= \|[Id - X(tXX)^{-1}tX]Y\|^2 = \|MY\|^2 = {}^tY^tMMY\end{aligned}$$

Or M projecteur orthogonal sur \mathcal{X}^\perp donc : ${}^tM = M$; $M.M = M$ et $MX = 0$.

Donc

$$\|Y - X\hat{\beta}\|^2 = {}^tYMY = {}^t(X\beta + \epsilon)M(X\beta + \epsilon) = {}^t\epsilon M\epsilon.$$

D'après le lemme :

$$E(\|Y - X\hat{\beta}\|^2) = E({}^t\epsilon M\epsilon) = \sigma^2 \text{trace} M = \sigma^2(n-p) \bullet$$

Estimation dans la cas $\text{Var}(\epsilon) = \sigma^2 \Gamma$

- Γ est une matrice symétrique, définie positive donc diagonalisable et à valeurs propres > 0 .

$$\Gamma = {}^t U \Lambda U \text{ avec } {}^t U U = Id$$

Posons $\sqrt{\Lambda}$ la matrice diagonale des racines carrés des valeurs propres de Γ et le changement de variable $Z = HY$ avec $H = \sqrt{\Lambda}^{-1} U$ alors : $\text{Var}(Z) = \sigma^2 Id$ et on applique au modèle $Z = HX\beta + \epsilon_z$ les résultats précédents.

Interprétation géométrique ; propriété de W. Kruskal 1968

$$\hat{\beta} = (X' \Gamma^{-1} X)^{-1} X' \Gamma^{-1} Y = (X' X)^{-1} X' Y$$

l'espace \mathcal{X} est invariant par l'opérateur Γ ($\Gamma X = X$)

$$\hat{\sigma}^2 = \frac{1}{n} \|Y - X \hat{\beta}_{ML}\|_{\Gamma^{-1}}^2 = \frac{1}{n} \|Y - X \hat{\beta}_{Id}\|^2$$

les espaces \mathcal{X} et \mathcal{X}^\perp sont invariants par l'opérateur Γ

Théorème de Kruskal, démonstration

Les deux estimateurs $\hat{\beta}_{\text{Id}}$ et $\hat{\beta}_{\Gamma^{-1}}$ sont identiques si et seulement si \mathcal{X} est invariant par la matrice Γ .

$\hat{\beta}_{\text{Id}}$ est définie par : $\langle y - X\hat{\beta}_{\text{Id}}, z \rangle_{\text{Id}} = 0, \forall z \in \mathcal{X};$

$\hat{\beta}_{\Gamma^{-1}}$ est définie par : $\langle y - X\hat{\beta}_{\Gamma^{-1}}, z \rangle_{\Gamma^{-1}} = \langle y - X\hat{\beta}_{\Gamma^{-1}}, \Gamma^{-1}z \rangle_{\text{Id}} = 0.$

De plus \mathcal{X} invariant par la matrice Γ (ou Γ inv.)

$$\Leftrightarrow \Gamma\mathcal{X} = \mathcal{X} \Leftrightarrow \Gamma^{-1}\mathcal{X} = \mathcal{X} \Leftrightarrow \Gamma^{-1}z \in \mathcal{X}, \forall z \in \mathcal{X}.$$

a) $\hat{\beta}_{\text{Id}} = \hat{\beta}_{\Gamma^{-1}} \Rightarrow \langle y - X\hat{\beta}_{\text{Id}}, \Gamma^{-1}z \rangle_{\text{Id}} = 0$, donc $\Gamma^{-1}z \in \mathcal{X}, \forall z \in \mathcal{X}.$

b) \mathcal{X} est invariant par Γ (ou Γ^{-1}) alors la condition sur $\hat{\beta}_{\Gamma^{-1}}$:
 $\langle y - X\hat{\beta}_{\Gamma^{-1}}, \Gamma^{-1}z \rangle_{\text{Id}} = 0$ se transforme en : $\langle y - X\hat{\beta}_{\Gamma^{-1}}, z \rangle_{\text{Id}} = 0.$

De par l'unicité $\hat{\beta}_{\text{Id}} = \hat{\beta}_{\Gamma^{-1}}.$

Matrice d'information :

Posons $\gamma = (\beta, \theta)$ et

$$\mathcal{I}_{\beta, \theta} = E_{\beta, \theta} \left[-\frac{\partial^2 \log f(\beta, \theta; y)}{\partial \gamma \partial \gamma'} \right]$$

alors

$$\mathcal{I}_{\beta, \theta} = E_{\beta, \theta} \left[\frac{1}{2} \frac{\partial^2 l(\beta, \theta)}{\partial \gamma \partial \gamma'} \right] = E_{\beta, \theta} \left[\frac{1}{2} \begin{pmatrix} \frac{\partial U_{\beta}}{\partial \beta'} & \frac{\partial U_{\beta}}{\partial \theta'} \\ \frac{\partial U_{\theta}^{ML}}{\partial \beta'} & \frac{\partial U_{\theta}^{ML}}{\partial \theta'} \end{pmatrix} \right].$$

On vérifie aisément que $\frac{\partial U_{\beta}}{\partial \beta'} = 2 X' \Gamma_{\theta}^{-1} X$ et que $E_{\beta, \theta} \left[\frac{\partial U_{\beta}}{\partial \theta'} \right] = 0$.

D'autre part :

$$\begin{aligned} \left[\frac{\partial U_{\theta}^{ML}}{\partial \theta'} \right]_{ij} &= \text{tr}(\Gamma_{\theta}^{-1} (\frac{\partial^2 \Gamma_{\theta}}{\partial \theta_i \partial \theta_j} - \frac{\partial \Gamma_{\theta}}{\partial \theta_i} \Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta_j})) \\ &\quad - (y - X\beta)' \Gamma_{\theta}^{-1} (\frac{\partial^2 \Gamma_{\theta}}{\partial \theta_i \partial \theta_j} - 2 \frac{\partial \Gamma_{\theta}}{\partial \theta_i} \Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta_j}) \Gamma_{\theta}^{-1} (y - X\beta) \end{aligned}$$

Donc

$$\mathcal{I}_{\beta, \theta} = \begin{pmatrix} \mathcal{I}_{\beta} = X' \Gamma_{\theta}^{-1} X & 0 \\ 0 & \mathcal{I}_{\theta}^{ML} = \left[\frac{1}{2} \text{tr}(\Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta_i} \Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta_j}) \right]_{i,j=1,\dots,K} \end{pmatrix}$$

Le maximum de vraisemblance restreint : REML

- **La vraisemblance restreinte** : c'est la vraisemblance marginale après intégration sur β

$$f_{RE}(\theta; y) = \frac{1}{(2\pi)^{(N-p)/2}} |\Gamma_\theta|^{-1/2} |X' \Gamma_\theta^{-1} X|^{-1/2} \exp\left\{-\frac{1}{2} y' P_\theta y\right\}$$

et

$$l_{RE}(\theta) = -2 \log(f_{RE}(\theta; y))$$

- **Estimateur maximum de vraisemblance restreinte**

$$\hat{\theta}_{REML} = \arg \min_{\theta} (y' P_\theta y + \log(|\Gamma_\theta|) + \log(|X' \Gamma_\theta^{-1} X|))$$

Fonction score

$$\begin{aligned}U_{\theta}^{REML} &= \frac{\partial l_{RE}(\theta)}{\partial \theta} \\&= -y' P_{\theta} \frac{\partial \Gamma_{\theta}}{\partial \theta} P_{\theta} y + \text{tr}(\Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta}) \\&\quad - \text{tr}((X' \Gamma_{\theta}^{-1} X)^{-1} X' \Gamma_{\theta}^{-1} \frac{\partial \Gamma_{\theta}}{\partial \theta} \Gamma_{\theta}^{-1} X) \\&= -y' P_{\theta} \frac{\partial \Gamma_{\theta}}{\partial \theta} P_{\theta} y + \text{tr}(P_{\theta} \frac{\partial \Gamma_{\theta}}{\partial \theta})\end{aligned}\tag{3}$$

et $\hat{\beta}_{REML}$ est solution de l'équation $U_{\beta}(\hat{\theta}_{REML}) = 0$.

Matrice d'information associée au vecteur y

Posons

$$\mathcal{I}_\theta^{REML} = E_\theta \left[-\frac{\partial^2 \log f_{RE}(\theta; y)}{\partial \theta \partial \theta'} \right]$$

alors

$$\mathcal{I}_\theta^{REML} = E_\theta \left[\frac{1}{2} \frac{\partial^2 l_{RE}(\theta)}{\partial \theta \partial \theta'} \right] = E_\theta \left[\frac{1}{2} \frac{\partial U_\theta^{REML}}{\partial \theta'} \right].$$

Un calcul similaire au cas précédent

$$\mathcal{I}_\theta^{REML} = \left[\frac{1}{2} \text{tr} \left(P_\theta \frac{\partial \Gamma_\theta}{\partial \theta_i} P_\theta \frac{\partial \Gamma_\theta}{\partial \theta_j} \right) \right]_{i,j=1,\dots,K}$$

Remarque :

- En résumé :

$\hat{\theta}_{ML}$ est donc solution de la minimisation du critère :

$$\text{CritèreML} = y' P_{\theta} y + \log(|\Gamma_{\theta}|);$$

$\hat{\theta}_{REML}$ est solution de la minimisation du critère :

$$\text{CritèreREML} = \text{CritèreML} + \log(|X' \Gamma_{\theta}^{-1} X|)$$

et $\hat{\beta}_{\cdot} = (X' \Gamma_{\hat{\theta}_{\cdot}}^{-1} X)^{-1} X' \Gamma_{\hat{\theta}_{\cdot}}^{-1} y$.

- Remarquant que $E_{\theta}(P_{\theta} y) = 0$ et $P_{\theta} \Gamma_{\theta} P_{\theta} = P_{\theta}$ alors

$$E_{\theta}(y' P_{\theta} \frac{\partial \Gamma_{\theta}}{\partial \theta} P_{\theta} y) = \text{tr}(P_{\theta} \frac{\partial \Gamma_{\theta}}{\partial \theta}).$$

La fonction score U_{θ}^{REML} est donc une statistique centrée contrairement à la fonction score U_{θ}^{ML} .

Critères de choix de modèles.

Les critères d'informations que l'on cherche à minimiser sont construits sur la log-vraisemblance en $\hat{\beta}_{ML}$ et $\hat{\theta}_{ML}$ notée $\mathcal{L}(\mathcal{M})$.

On désigne par $q(\mathcal{M})$ le nombre de paramètres estimés dans le modèle ($q(\mathcal{M}) = p + K$).

AIC : Akaike Information Criterium

$$-2\mathcal{L}(\mathcal{M}) + 2 * q(\mathcal{M})$$

BIC : Bayesian Information Criterium

$$-2\mathcal{L}(\mathcal{M}) + \ln(n) * q(\mathcal{M})$$

Le modèle linéaire mixte : L2M

$$Y = X\beta + \mathbb{Z}U + \epsilon = X\beta + \sum_{k=1}^K Z_k U_k + \epsilon$$

- $\epsilon \sim \mathcal{N}_{\mathbb{R}^N}(0, R = \theta_0 V_0)$, V_0 est une matrice connue.
- $U_k \sim \mathcal{N}_{\mathbb{R}^{q_k}}(0, \theta_k G_k)$ pour tout $k = 1, \dots, K$; les G_k sont des matrices connues.

U_1, U_2, \dots, U_k sont les effets aléatoires non observés; ils sont indépendants entre eux et indépendants de ϵ .

- $U \sim \mathcal{N}_{\mathbb{R}^q}(0, G_\theta)$ où $q = \sum_{k=1}^K q_k$

$$\text{Var}(Y) = \Gamma_\theta = R + \mathbb{Z} G_\theta \mathbb{Z}' = \sum_{k=0}^K \theta_k V_k \text{ où } V_k = Z_k G_k Z_k'$$

les θ_k ($\in \mathbb{R}^+$) sont appelés les composantes de la variance.

Simplification des fonctions scores U_{θ}^{ML} et U_{θ}^{REML} du modèle mixte

Dans ce cas particulier on a : $\frac{\partial \Gamma_{\theta}}{\partial \theta_k} = V_k$:

$$\begin{aligned} U_{\theta}^{ML} : y' P_{\theta} V_k P_{\theta} y &= \text{tr}(\Gamma_{\theta}^{-1} V_k) \text{ pour } k = 0, \dots, K \\ U_{\theta}^{REML} : y' P_{\theta} V_k P_{\theta} y &= \text{tr}(P_{\theta} V_k) \text{ pour } k = 0, \dots, K \end{aligned}$$

Comme pour $k = 0, \dots, K$

$$\begin{aligned} \text{tr}(\Gamma_{\theta}^{-1} V_k) &= \sum_{j=1}^K \text{tr}(\Gamma_{\theta}^{-1} V_k \Gamma_{\theta}^{-1} V_j) \theta_j \\ \text{et } \text{tr}(P_{\theta} V_k) &= \sum_{j=1}^K \text{tr}(P_{\theta} V_k P_{\theta} V_j) \theta_j \end{aligned}$$

On obtient ainsi 2 systèmes linéaires identiques :

$$2\mathcal{I}_{\theta} \theta = F_{\theta} \text{ où } F_{\theta} \text{ est le vecteur } \{y' P_{\theta} V_k P_{\theta} y\}$$

L'algorithme EM

Principe : étant donné un vecteur aléatoire observé Y et un vecteur aléatoire non observé (ici les effets aléatoires) U , on cherche des statistiques exhaustives, fonction des données complètes $x = (y', u')'$ qui permettent de réaliser l'estimation des paramètres inconnus γ : notées $t(x)$. On obtient un algorithme qui à chaque itération $[t]$ pour une valeur courante du paramètre $\gamma^{[t]}$ se décompose en 2 étapes :

- étape E : calculer l'espérance conditionnelle de $t(x)$ sachant les données observées y et la valeur $\gamma^{[t]}$.
- étape M : maximiser la vraisemblance des données complètes en remplaçant les statistiques exhaustives par l'espérance conditionnelle et obtenir ainsi $\gamma^{[t+1]}$.

Le modèle linéaire mixte : L2M

$$Y = X\beta + \sum_{k=1}^K Z_k U_k + \epsilon ; \epsilon \sim \mathcal{N}_{\mathbb{R}^N}(0, \theta_0 V_0), U_k \sim \mathcal{N}_{\mathbb{R}^{q_k}}(0, \theta_k G_k).$$

Donc si les U_k étaient observées, les estimations des paramètres seraient obtenues par :

$$\hat{\theta}_k = \frac{U_k G_k^{-1} U_k'}{q_k} \text{ et } \hat{\beta} = (X' V_0^{-1} X)^{-1} X' V_0^{-1} (y - \sum_{k=1}^K Z_k U_k)$$

On vérifie alors aisément que :

$$E(U_k G_k^{-1} U_k' | y) = \theta_k^2 (y - X\beta)' \Gamma_\theta^{-1} V_j \Gamma_\theta^{-1} (y - X\beta) + q_k \theta - \theta^2 \text{tr}(\Gamma_\theta^{-1} V_j)$$

$$E(y - \sum_{k=1}^K Z_k U_k | y) = X\beta + \theta_0 V_0 \Gamma_\theta^{-1} (y - X\beta)$$

D'où l'algorithme EM pour ML :

$$\begin{cases} q_k \theta_k^{[t+1]} = \theta_k^{2[t]} (y - X\beta^{[t]})' \Gamma_{\theta^{[t]}}^{-1} V_j \Gamma_{\theta^{[t]}}^{-1} (y - X\beta^{[t]}) \\ \quad + q_k \theta^{[t]} - \theta^{2[t]} \text{tr}(\Gamma_{\theta^{[t]}}^{-1} V_j) \\ X\beta^{[t+1]} = (X' V_0^{-1} X)^{-1} X' V_0^{-1} [X\beta^{[t]} + \theta_0^{[t]} V_0 \Gamma_{\theta^{[t]}}^{-1} (y - X\beta^{[t]})] \end{cases}$$

La 1^{re} partie de l'algorithme peut aussi s'écrire :

$$\begin{cases} q_k \theta_k^{[t+1]} = \theta_k^{2[t]} y' P_{\theta^{[t]}} V_j P_{\theta^{[t]}} y + q_k \theta^{[t]} - \theta^{2[t]} \text{tr}(\Gamma_{\theta^{[t]}}^{-1} V_j) \end{cases}$$

et en remplaçant $\Gamma_{\theta^{[t]}}^{-1}$ par $P_{\theta^{[t]}}$ on obtient l'algorithme EM pour REML.