

Modèles linéaires mixtes

Sandrine Le Squin

Février 2019

Exemple

Comment évolue le nombre de régime au jeune âge d'une famille de palmier à huile ?

72 palmiers.

On dispose du nombre de régime produit annuellement pour chaque palmier à $t=0, 1, 2, 3$ et 4 ans après l'entrée en production (= jeune âge)

Modèle mixte pour données longitudinales

- ▶ En utilisant le package ggplot2, représenter le nombre de régime (bn) en fonction du temps (time), avec un graphique par palmier. Quel type de modélisation vous semble le plus adapté?
- ▶ Faire la régression linéaire du nombre de régime en fonction du temps. Représentez les résidus en fonction de chaque palmier. Que constatez vous ?

- ▶ Avec la fonction lmer du package lme4, estimez les paramètres des modèles suivants :

$$Y_{ij} = \beta_1 + \beta_2 x_i + b_j + \epsilon_{ij}, \quad i = 0, \dots, 4 \text{ et } j = 1, \dots, 72$$

$$\text{avec } b_j \sim N(0, \sigma_b), \quad \epsilon_{ij} \sim N(0, \sigma^2)$$

$$Y_{ij} = \beta_1 + \beta_2 x_i + a_j x_i + \epsilon_{ij}, \quad i = 0, \dots, 4 \text{ et } j = 1, \dots, 72$$

$$\text{avec } a_j \sim N(0, \sigma_a), \quad \epsilon_{ij} \sim N(0, \sigma^2)$$


$$Y_{ij} = \beta_1 + \beta_2 x_i + b_j + a_j x_i + \epsilon_{ij}, \quad i = 0, \dots, 4 \text{ et } j = 1, \dots, 72$$

$$\text{avec } u_j = \begin{bmatrix} b_j \\ a_j \end{bmatrix} \sim N\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} \sigma_b^2 & \rho_{ab} \\ \rho_{ab} & \sigma_a^2 \end{bmatrix}\right)$$

Modèle mixte pour données longitudinales

Nombre de régime en fonction du temps, par palmier

```
ggplot(long.data, aes(time, bn))+geom_point()+geom_line()  
+ facet_wrap(~palmId)
```




Modèle mixte pour données longitudinales

Régression linéaire du nombre de régime en fonction du temps

$$Y_{ij} = \beta_1 + \beta_2 x_i + \epsilon_{ij}, \quad i = 0, \dots, 4 \text{ et } j = 1, \dots, 72$$

```
> mod <- lm(bn~time, data = long.data)
> res <- resid(mod)
> ggplot(long.data, aes(reorder(palmId, res), res))+geom_point()
  geom_hline(yintercept=0, colour=2)
```



Modèle mixte pour données longitudinales

Modèle avec intercept aléatoire

$$Y_{ij} = \beta_1 + \beta_2 x_i + b_j + \epsilon_{ij}, \quad i = 0, \dots, 4 \text{ et } j = 1, \dots, 72$$

```
> mod1 <- lmer(bn ~ time + (1|palmId), data = long.data)
> summary(mod1)
...
```

Random effects:

Groups	Name	Variance	Std.Dev.
palmId	(Intercept)	2.08	1.442
Residual		16.33	4.042

Number of obs: 360, groups: palmId, 72

Fixed effects:

Estimate	Std. Error	df	t value	Pr(> t)
(Intercept)	34.0472	0.4062	255.9830	83.82 <2e-16 ***
time	-4.3597	0.1506	287.0000	-28.95 <2e-16 ***

Modèle mixte pour données longitudinales

Modèle avec pente aléatoire

$$Y_{ij} = \beta_1 + \beta_2 x_i + a_j x_i + \epsilon_{ij}, \quad i = 0, \dots, 4 \text{ et } j = 1, \dots, 72$$

```
> mod2 <- lmer(bn ~ time + (0+time|palmId), data = long.data)
> summary(mod2)
...
Random effects:
Groups      Name Variance Std.Dev.
palmId      time  0.4458   0.6677
Residual                15.7446   3.9679
Number of obs: 360, groups:  palmId, 72

Fixed effects:
Estimate Std. Error      df    t value Pr(>|t|)
(Intercept)  34.0472    0.3622  287.0000   94.00  <2e-16 ***
time         -4.3597    0.1675  238.5689  -26.03  <2e-16 ***
```

Modèle mixte pour données longitudinales

Modèle avec pente et intercept aléatoire (corrélation)

$$Y_{ij} = \beta_1 + \beta_2 x_i + b_j + a_j x_i + \epsilon_{ij}, i = 0, \dots, 4 \text{ et } j = 1, \dots, 72$$

```
> mod3 <- lmer(bn ~ time + (time|palmId), data = long.data)
> summary(mod3)
```

Random effects:

Groups	Name	Variance	Std.Dev.	Corr
palmId	(Intercept)	1.113	1.0550	
	time	0.424	0.6512	-0.19
Residual		15.286	3.9097	
Number of obs: 360, groups: palmId, 72				

Fixed effects:

Estimate	Std. Error	df	t value	Pr(> t)	
(Intercept)	34.0472	0.3779	71.0000	90.09	<2e-16 ***
time	-4.3597	0.1647	71.0001	-26.47	<2e-16 ***

Modèle mixte pour données longitudinales

Modèle avec pente et intercept aléatoire

$$Y_{ij} = \beta_1 + \beta_2 x_i + b_j + a_j x_i + \epsilon_{ij}, \quad i = 0, \dots, 4 \text{ et } j = 1, \dots, 72$$

Est ce que b et a sont indépendant?

```
> mod4<-lmer(bn~time+(1|palmId)+(0+time|palmId),  
data=long.data)  
summary(mod4)  
Random effects:  
Groups      Name          Variance Std.Dev.  
palmId      (Intercept)    0.8131  0.9017  
palmId.1    time          0.3687  0.6072  
Residual                    15.4016  3.9245
```

Modèle mixte pour données longitudinales

Comparaison des deux modèles

```
anova(mod3, mod4) # refitting model(s) with ML
```

	Df	AIC	BIC	logLik	deviance	Chisq	Chi Df	Pr(>Chisq)
mod4	5	2065.56	2084.99	-1027.78	2055.56			
mod3	6	2067.54	2090.86	-1027.77	2055.54	0.02	1	0.9023

⇒ On conserve le modèle avec intercept aléatoire et pente aléatoire indépendante

Modèle mixte pour données longitudinales

Test de la pente

```
anova(mod4, mod2) # refitting model(s) with ML
```

	Df	AIC	BIC	logLik	deviance	Chisq	Chi Df	Pr(>Chisq)
mod2	4	2064.24	2079.78	-1028.12	2056.24			
mod4	5	2065.56	2084.99	-1027.78	2055.56	0.68	1	0.4085

Test de l'intercept


```
anova(mod4, mod2) # refitting model(s) with ML
```

	Df	AIC	BIC	logLik	deviance	Chisq	Chi Df	Pr(>Chisq)
mod1	4	2068.68	2084.23	-1030.34	2060.68			
mod4	5	2065.56	2084.99	-1027.78	2055.56	5.13	1	0.0236

Modèle mixte pour données longitudinales

```
y1 <- predict(mod1); # conditionnelle.  
y2 <- predict(mod2); # conditionnelle  
y3 <- predict(mod3); # conditionnelle  
# ajouter re.form=NA pour pred marginale (voir long_data.R)  
  
long.data$y1 <- y1;  
long.data$y2 <- y2;  
long.data$y3 <- y3  
  
## subset de 9 individus  
sub <- subset(long.data, palmId %in% c("57_11","37_5","56_13",  
"34_7","54_13","56_14","57_13","37_6","37_23"))  
sub <- droplevels(sub)  
  
p <- ggplot(sub, aes(time, y1)) + geom_line(colour = "red")  
p <- p + geom_line(aes(time, y2), col = "blue")  
p + geom_point(data=sub, aes(time, bn))+facet_wrap(~palmId)
```




Modèle mixte pour données longitudinales



Modèle mixte pour données longitudinales

Autre représentations possibles

```
# intercept aleatoire
ggplot(sub,aes(time,y1,group=palmId))+geom_line(colour="red")
# pente aleatoire
ggplot(sub,aes(time,y2,group=palmId))+geom_line(colour="blue")
# intercept + pente aleatoire
ggplot(sub,aes(time,y3,group=palmId))+
geom_line(colour="forestgreen")
```



Modèle mixte pour données longitudinales

Note sur l'écriture matricielle des modèles:

Partie fixe des modèles mixtes (communs aux 4 modèles)

Rappel : $Y = X\beta + Zu + \epsilon$

$$Y_{360 \times 1} = \begin{bmatrix} y_{0,1} \\ y_{1,1} \\ y_{2,1} \\ y_{3,1} \\ y_{4,1} \\ \dots \\ y_{4,72} \end{bmatrix}, X_{360 \times 2} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ \dots & \dots \\ 1 & 4 \end{bmatrix}, \beta = [\beta_1, \beta_2]'$$

$y_{0,1}$: Nombre de régimes au temps 0 du palmier 1 etc.

Modèle mixte pour données longitudinales

Note sur l'écriture matricielle des modèles:

Modèle avec intercept aléatoire

$$Z_{360 \times 72} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 1 & 0 & \dots & 0 \\ 1 & 0 & \dots & 0 \\ 1 & 0 & \dots & 0 \\ 1 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 1 \end{bmatrix} \text{ et } u_{1 \times 72} = [b_1, \dots, b_{72}]'$$

Modèle mixte pour données longitudinales

Note sur l'écriture matricielle des modèles:

Modèle avec pente aléatoire

$$Z_{360 \times 72} = \begin{bmatrix} 0 & 0 & \dots & 0 \\ 1 & 0 & \dots & 0 \\ 2 & 0 & \dots & 0 \\ 3 & 0 & \dots & 0 \\ 4 & 0 & \dots & 0 \\ & & \ddots & \\ 0 & 0 & \dots & 4 \end{bmatrix} \text{ et } u_{1 \times 72} = [a_1, \dots, a_{72}]'$$

Modèle mixte pour données longitudinales

Note sur l'écriture matricielle des modèles:

Modèle avec intercept et pente aléatoire

$$Z = \begin{bmatrix} Z_1 & 0 & \dots & 0 \\ 0 & Z_2 & \dots & 0 \\ & & \ddots & \\ 0 & 0 & \dots & Z_{72} \end{bmatrix} \text{ et } u = [u_1, \dots, u_{72}]' \text{ avec,}$$

$$\forall j = 1, \dots, 72, Z_j = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \end{bmatrix} \text{ et } u_j = \begin{bmatrix} b_j \\ a_j \end{bmatrix}$$

Exemple


On cherche à comparer le rendement en huile à 4 ans de 25 familles de palmiers. Dispositif expérimental :

- ▶ 25 familles de palmiers à huile
- ▶ 6 répétitions
- ▶ 5 blocs par répétition (blocs car hétérogénéité du terrain)
- ▶ 5 parcelles élémentaires par blocs. Taille des parcelles = 12 palmiers

Répartition aléatoire des 25 traitements dans les 5 blocs de taille 5, répétés 6 fois, de telle sorte que chaque paire de traitement soit présente une fois dans chaque bloc.

Modèle mixte avec effets aléatoires emboîtés

Représentation graphique de l'essai




Modèle mixte avec effets aléatoires emboîtés

- ▶ Avec ggplot2, représenter graphiquement le rendement en huile de chaque famille (facet_wrap) en fonction de la répétition.
- ▶ Dans un premier temps, nous ignorons l'effet bloc. Quel(s) effet(s) aléatoire(s) pourraient être intégrés dans le modèle ?
- ▶ Représentez graphiquement l'interaction replicate*family
- ▶ Avec la fonction lmer du package lme4, estimez les paramètres des modèles suivants :
 - $Y_{ijk} = \mu + \beta_i + b_j + \epsilon_{ijk}, i = 1, \dots, 25, j = 1, \dots, 6, k = 1, \dots, 12$
 $b_j \sim N(0, \sigma_b^2), \epsilon_{ijk} \sim N(0, \sigma^2)$
 - $Y_{ijk} = \mu + \beta_i + b_j + b_{ij} + \epsilon_{ijk}, i = 1, \dots, 25, j = 1, \dots, 6, k = 1, \dots, 12$
 $b_j \sim N(0, \sigma_1^2), b_{ij} \sim N(0, \sigma_2^2), \epsilon_{ijk} \sim N(0, \sigma^2)$
- ▶ Le facteur bloc permet il de mieux prendre en compte l'hétérogénéité du terrain ?
- ▶ Y a t'il un effet famille ?

Modèle mixte avec effets aléatoires emboîtés

Rendement en huile en fonction de la famille et de la répétition


```
> ldesign <- read.csv2("lattice.design.csv")  
> ggplot(ldesign, aes(replicate, yield)) +  
  geom_boxplot(aes(fill = replicate)) + facet_wrap(~family)
```



Modèle mixte avec effets aléatoires emboîtés

Plot de l'interaction replicate x family

```
>attach( ldesign )  
>interaction.plot(family, replicate, yield, las = 1)  
>detach()
```



Modèle mixte avec effets aléatoires emboîtés

Modèle avec répétition en aléatoire

$$Y_{ijk} = \mu + \beta_i + b_j + \epsilon_{ijk}, \quad i = 1, \dots, 25, \quad j = 1, \dots, 6, \quad k = 1, \dots, 12$$

```
> mod <- lmer(yield ~ family + (1|replicate), data = ldesign)
> summary(mod)
```

Random effects:

Groups	Name	Variance	Std.Dev.
replicate	(Intercept)	0.1927	0.4390
Residual		0.9996	0.9998

Number of obs: 1778, groups: replicate, 6

Modèle mixte avec effets aléatoires emboîtés

Modèle avec répétition + famille dans répétition en aléatoire

$$Y_{ijk} = \mu + \beta_i + b_j + b_{ij} + \epsilon_{ijk}, i = 1, \dots, 25, j = 1, \dots, 6, k = 1, \dots, 12$$

```
>mod2 <- lmer(yield ~ family + (1|replicate/family),
  data = ldesign)
>summary(mod2)
Random effects:
Groups                Name                Variance Std.Dev.
family:replicate      (Intercept)    0.06127   0.2475
replicate              (Intercept)    0.19002   0.4359
Residual                                0.94969   0.9745
Number of obs: 1778, groups: family:replicate, 150;
replicate, 6
```

Modèle mixte avec effets aléatoires emboîtés

Comparaison des modèles

`anova(mod, mod2)`

	Df	AIC	BIC	logLik	deviance	Chisq	Chi Df	Pr(>Chisq)
mod	27	5098.13	5246.17	-2522.06	5044.13			
mod2	28	5089.05	5242.59	-2516.53	5033.05	11.07	1	0.0009

Modèle mixte avec effets aléatoires emboîtés

Ajout de l'effet bloc

L'effet famille est emboîté dans bloc lui même emboîté dans répétition

```
> mod3 <- lmer(yield ~ family + (1|replicate/block/family),  
  data = ldesign)  
> summary(mod3)
```

Random effects:

Groups	Name	Variance	Std.Dev.
family:(block:replicate)	(Intercept)	0.053566	0.2314
block:replicate	(Intercept)	0.009235	0.0961
replicate	(Intercept)	0.188516	0.4342
Residual		0.949688	0.9745

Modèle mixte avec effets aléatoires emboîtés

Comparaison des modèles

```
anova(mod3, mod2)
```

	Df	AIC	BIC	logLik	deviance	Chisq	Chi Df	Pr(>Chisq)
mod2	28	5089.05	5242.59	-2516.53	5033.05			
mod3	29	5090.08	5249.09	-2516.04	5032.08	0.98	1	0.3227

Modèle mixte avec effets aléatoires emboîtés

Comparaison des modèles

```
anova(mod3, mod2)
```

	Df	AIC	BIC	logLik	deviance	Chisq	Chi Df	Pr(>Chisq)
mod2	28	5089.05	5242.59	-2516.53	5033.05			
mod3	29	5090.08	5249.09	-2516.04	5032.08	0.98	1	0.3227

Modèle mixte avec effets aléatoires emboîtés

Test de l'effet famille

- Y a t'il un effet famille ?

→ pseudo-test F, basé sur l'approximation de Satterthwaite. Disponible dans le package `lmerTest`

	Sum Sq	Mean Sq	NumDF	DenDF	F value	Pr(>F)
family	354.81	14.78	24.00	118.38	15.57	0.0000

```
> library(lmerTest)
> mod2 <- lmer(yield ~ family + (1|replicate/family),
data = ldesign)
> summary(mod2)
> anova(mod2)
```

Modèle mixte avec effets aléatoires emboîtés

Note sur l'écriture matricielle des modèles:

Partie fixe

Rappel : $Y = X\beta + Zu + \epsilon$

$$Y_{1778 \times 1} = \begin{bmatrix} y_{1,1,1} \\ y_{1,1,2} \\ \dots \\ y_{25,6,12} \end{bmatrix}, X_{1778 \times 26} = \begin{bmatrix} 1 & 1 & 0 & \dots & 0 \\ 1 & 1 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots \\ 1 & 0 & 0 & \dots & 1 \end{bmatrix}$$

$$\beta = [\mu, \beta_1, \dots, \beta_{26}]'$$

Normalement, $25 \times 6 \times 12 = 1800$ observations.

Mais quelques palmiers morts, il y a 1778 observations (voir `nrow(ldeggin)`)

Modèle mixte avec effets aléatoires emboîtés

Note sur l'écriture matricielle des modèles:

Modèle avec replicate en aléatoire

$$Z_{1778 \times 6} = \begin{bmatrix} Z_1 & 0 & \dots & 0 \\ 0 & Z_2 & \dots & 0 \\ & & \ddots & \\ 0 & 0 & \dots & Z_6 \end{bmatrix} \text{ et } u = [b_1, \dots, b_6]' \text{ avec,}$$

$$\forall j = 1, \dots, 6, Z_j = \begin{bmatrix} 1 \\ 1 \\ \dots \\ 1 \end{bmatrix}, Z_j \text{ de dimension } n_j \times 1$$

Théoriquement, $n_j = 25 \times 12 = 300$ mais palmiers morts, donc variable selon la répétition

Modèle mixte avec effets aléatoires emboîtés

Note sur l'écriture matricielle des modèles:

Modèle avec replicate et famille dans replicate en aléatoire

$$Z_{1778 \times 156} = \left[\begin{array}{cccc|ccc} Z_{R1} & 0 & \dots & 0 & Z_{F1R1} & \dots & 0 \\ 0 & Z_{R2} & \dots & \dots & \dots & \dots & 0 \\ & & \ddots & & & \ddots & \\ 0 & 0 & \dots & Z_{R6} & 0 & \dots & Z_{F25R6} \end{array} \right]$$

$$u = [b_1, \dots, b_6, b_{1,1}, \dots, b_{25,6}]'$$

$$Z_{Rj} = \begin{bmatrix} 1 \\ 1 \\ \dots \\ 1 \end{bmatrix}, \quad Z_{FiRj} = \begin{bmatrix} 1 \\ 1 \\ \dots \\ 1 \end{bmatrix} \quad i = 1, \dots, 25, j = 1, \dots, 6$$

Z_{Rj} de dimension $n_j \times 1$, $n_j \simeq 300$, Z_{FiRj} de dimension $n_{ij} \times 1$, $n_{ij} \simeq 12$

Théoriquement, $n_j = 25 \times 12 = 300$ et $n_{ij} = 12$ mais quelques palmiers morts

Modèle mixte avec effets aléatoires emboîtés

Ajout d'effet(s) aléatoire(s) et dépendance des observations

→ $Cov(Y_{ijk}, Y_{i'j'k'}), \forall i = 1, \dots, 25, j = 1, \dots, 6, k = 1, \dots, 12$?

Exemple du modèle avec effets aléatoires 1|replicate/family

$$Cov(Y_{ijk}, Y_{i'j'k'}) = \begin{cases} \sigma_1^2 + \sigma_2^2 + \sigma^2 & \text{si } i = i', j = j', k = k' \\ \sigma_1^2 + \sigma_2^2 & \text{si } i = i', j = j', k \neq k' \\ \sigma_1^2 & \text{si } i \neq i', j = j', k \neq k' \\ 0 & \text{sinon} \end{cases}$$

→ Des palmiers appartenant à la même famille et plantés dans la même répétition ne sont pas indépendants

→ Des palmiers appartenant à la même répétition ne sont pas indépendants

Note sur les contrastes dans R

Par défaut dans R, c'est la famille F1 qui est la modalité de référence.

```
options()$contrasts  
contrasts(ldesign$family)
```

Pour modifier les contrastes, par exemple $\sum \beta_i = 0$:

```
options(contrasts = c("contr.sum", "contr.poly"))  
contrasts(ldesign$family)
```

- ▶ <http://bbolker.github.io/mixedmodels-misc/glmmFAQ.html>
- ▶ Bates D, Maechler M, Bolker B, Walker S (2014) *Fitting Linear Mixed-Effects Models Using lme4*
<https://cran.r-project.org/web/packages/lme4/vignettes/lmer.pdf>
- ▶ Bates D (2010) *lme4: Mixed-effect modeling with R*
http://webcom.upmf-grenoble.fr/LIP/Perso/DMuller/M2R/R_et_Mixed/documents/Bates-book.pdf
- ▶ <http://lme4.r-forge.r-project.org/>
voir par exemple présentation sur modèle mixte pour données longitudinales lme4.r-forge.r-project.org/slides/2011-03-16-Amsterdam/2Longitudinal.pdf
- ▶ Pinheiro J, Bates D, R-core (2013). *Mixed-Effects Models in S and S-PLUS*
(package nlme et pas lme4, mais des exemples simples dans le premier chapitre)